

Estimativa de Curvatura por Meio de Algoritmos de Machine Learning

Matheus P. Angarola Joao E.S. Batista Neto

Instituto de Ciências Matemáticas e de Computação (ICMC) - USP

matheuzu11@usp.br

Objetivos

O cálculo tradicional das curvaturas média e Gaussiana [1, 2] em malhas triangulares 3D é realizado geometricamente para cada vértice da malha. Esse processo, dependendo da quantidade de vértices, pode ser extremamente custoso em termos de recursos computacionais.


O presente projeto de Iniciação Científica propõe o uso de algoritmos de aprendizado de máquina para estimar as curvaturas médias e Gaussianas em malhas de rostos humanos, oferecendo uma alternativa mais eficiente às técnicas geométricas convencionais.

Essas curvaturas são essenciais para descrever a forma e os detalhes da superfície, sendo fundamentais em aplicações como reconstrução facial, detecção de rostos e análise de expressões faciais. A abordagem baseada em aprendizado de máquina busca complementar os métodos tradicionais, melhorando o desempenho ao tornar o processo mais rápido e eficaz.

Métodos e Procedimentos

O primeiro passo envolveu a criação de malhas tridimensionais de rostos humanos a partir dos pontos 3D gerados pela biblioteca *MediaPipe* [3]. Essas malhas foram utilizadas como base para o cálculo geométrico das curvaturas, que serviram como referência para a rotulação dos vértices.

Figura 1: Malha gerada pelo *MediaPipe*



As curvaturas média e Gaussiana foram calculadas para cada vértice da malha 3D, e esses valores foram utilizados como *labels* no treinamento dos modelos de *machine learning*. Essas *labels* forneceram uma base para que os modelos pudessem aprender a prever as curvaturas.

Após essa fase de rotulagem, foram extraídas as principais características das malhas (*features*). Essas *features* incluíram as coordenadas dos vértices (X, Y, Z), vetores normais e o grau de cada vértice, que descrevem a geometria local da malha. Esses atributos formaram o vetor de entrada necessário para os modelos de regressão, fornecendo os dados necessários para o aprendizado dos algoritmos.

Nessa última etapa, iniciou-se o processo de treinamento dos modelos de *machine learning*. O vetor de características, contendo as informações geométricas das malhas, foi utilizado como entrada, enquanto as curvaturas rotuladas serviram como saída (*labels*).

Resultados

Nos testes iniciais, foram utilizadas apenas as coordenadas dos vértices como entrada para os modelos. Resultando em um desempenho muito baixo, com precisão insuficiente para prever as curvaturas, mostrando que essas informações, por si só, não eram suficientes para capturar a complexidade das malhas 3D.

Após isso, foram incluídas as *features* calculadas, o que melhorou significativamente o desempenho. Nesse sentido, a acurácia dos modelos aumentou notavelmente com as novas características e os respectivos erros diminuíram. O *Random Forest*, por exemplo, obteve os resultados apresentados nas Figuras 2 e 3.

Em relação ao tempo de execução observou-se que, embora os modelos geométricos tivessem um tempo de execução menor para malhas pequenas, os algoritmos de regressão se mostraram muito mais eficientes em malhas maiores, como visto na Figura 4.

Figura 2: Curvatura Média (Precisão de 70%)




Figura 3: Curvatura Gaussiana (Precisão de 90%)





Figura 4: Comparação dos tempos de execução com o aumento do número de vértices.



Conclusões

Os resultados deste projeto mostram que algoritmos de aprendizado de máquina são uma alternativa eficiente às técnicas geométricas convencionais para estimar curvaturas médias e Gaussianas em malhas 3D, proporcionando uma boa precisão e otimização do tempo de execução, especialmente em malhas complexas.

Agradecimentos

O projeto é financiado pela FAPESP (Fundação de Amparo à Pesquisa do Estado de São Paulo), nº 2023/17907-0, sendo parte do projeto temático FAPESP de nº 2019/07316-0.

Referências

- [1] CRANE, K. Discrete differential geometry - cmu 15-458/858. aula 16., 2019.
- [2] CRANE, K. Discrete differential geometry - cmu 15-458/858. aula 17., 2019.
- [3] LUGARES, C., TANG, J., NASH, H., MCCLANAHAN, C., UBOWEJA, E., HAYS, M., ZHANG, F., CHANG, C.-L., YONG, M. G., LEE, J., ET AL. Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172* (2019).